대화형 부동산 데이터 분석 시스템

아파트 평균매매가격 RAG 챗봇 기획서

작성일자 2026년 10월 07일
문서버전 v1.0 (최종승인안)

1. 프로젝트 개요

1.1 정의 및 핵심 목적

아파트 평균매매가격 데이터(CSV)를 자연어로 질의하면 정확한 수치, 지역 간 비교, 시계열 추이를 즉시 제공하는 대화형 RAG 챗봇 시스템 구축.

1.2 배경 및 필요성

월별 245개 지역 × 10개월 = 2,450개 셀 데이터 보유. 수량 표 직접 탐색/계산 시 과다한 시간 소요를 수초 내 자연어 검색으로 해결.

1.3 기대 효과

- **사용자 측면:** 데이터 탐색시간 90% 이상 단축
- **업무 측면:** 반복적 시세/비교 분석 자동화
- **확장성 측면:** 타 부동산/경제 데이터 확장 구조

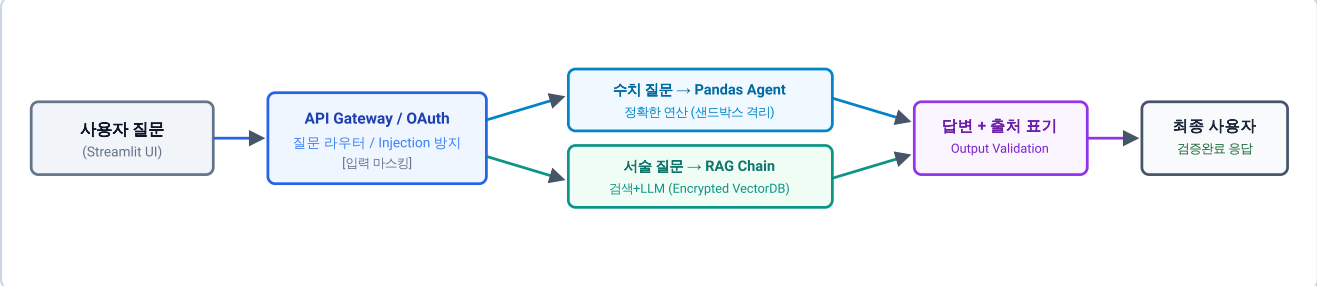
2. 대상 사용자 및 보안 정책

순위	사용자 구분	주요 니즈	접근 권한 / 보안 수준
1순위	**부동산 관심 일반인**	특정 지역 시세 및 단순 시계열 추이 확인	Read-Only, 공개 API Rate Limit 적용
2순위	**데이터 분석 실무자**	빠른 수치 추출, 다중 지역 비교 연산 분석	내부망 / 인증 토큰 기반 대량 조회

3. 주요 기능 (5대 핵심 기능)

ID	기능명	기능 설명	예시 질문
F1	**가격 조회**	특정 지역 및 시점의 정확한 평균매매가격 확인	"서울 8월 얼마야?"
F2	**지역 비교**	2개 이상 지역 간의 가격 차이 및 비율 비교 연산	"강남 vs 서초"
F3	**추이 조회**	특정 지역의 시계열 매매가격 변화 흐름 분석	"부산 최근 흐름"
F4	**순위 조회**	최고가/최저가 및 변동률 상위/하위 순위 추출	"많이 오른 곳 Top 5"
F5	**출처 표기**	답변 근거 데이터 출처(지역·기간) 자동 바인딩	메타데이터 자동 표기

4. 시스템 구성 및 데이터 보안 체계



5. 데이터 관리 및 보안 통제

항목	데이터 내용	보안 및 관리 대책
출처 (파일명)	평균매매가격_아파트.csv	무결성 검증 (SHA-256 Hash 바인딩 적용)
대상 기간	2025년 11월 ~ 2026년 8월 (10개월)	히스토리 백업 관리 및 데이터 변경 이력 소개 관리
지역 커버리지	245개 (전국/시도/권역/시군구 4계층)	계층별 매핑 테이블 검증을 통한 지역 오탐 방지
수치 단위	천원 단위 데이터	천원단위 오인 방지를 위한 자동 변환 유효성 검증

6. 기술 스택 및 보안 아키텍처

구분	선정 기술	보안 및 통제 강화 요소
LLM Engine	GPT-4o-mini	Data Non-Retention (DPA 계약 체결), API Key Vault 관리
Vector DB	Chroma DB	로컬 암호화 저장소 (AES-256 적용), 접근 권한 제어
Framework	LangChain	Prompt Injection 방지 가드레일 (NeMo Guardrails)
UI Framework	Streamlit	HTTPS 보안 적용, Session Timeout, Rate Limiting 통제
개발 언어	Python 3.11	정적 코드 분석(Bandit) 및 오픈소스 의존성 취약점 점검

7. 성공 기준 (KPI) 및 보안 목표

지표명	목표치	측정 및 검증 방법
수치 답변 정확도	95% 이상	골든셋 질문 30개 기준 자동화 연산 검증
평균 응답 시간	5초 이내	APM 실시간 성능 모니터링 모니터링
환각 발생률	0건	"데이터 없음" 명시, 출력 밸리데이터 가드레일 적용
출처 표기율	100% 명시	메타데이터 필수 바인딩 검증 모듈 적용
보안 취약점	Critical/High 0건	자동화 보안 스캔 및 모의 침투 테스트 진행

8. 주요 의사결정 사항 (의결 요청)

#	의사결정 항목	검토 옵션	최종 결정 (권장안)
1	**LLM 모델 선정**	OpenAI API vs 로컬 LLM	**OpenAI API** (보안 DPA 계약 체결 전제)
2	**시스템 배포 환경**	로컬 Server vs 클라우드 VPC	**클라우드 VPC** 격리 환경 배포
3	**차트 시각화 범위**	MVP 포함 vs 차기 고도화	**MVP 포함** (Streamlit Plotly 모듈)

9. 업무 분해 구조 (WBS) 및 체크리스트

🔴 필수: MVP (W1-1~3, W2-1~4, W3-1) 🟠 중요: 품질 (W3-2, W4-1) 🟢 권장: 운영 (W3-3, W4-2)

① 데이터 파이프라인 & 보안

- ☐ W1-1. CSV 로드, 정제 및 무결성 검증
- ☐ W1-2. RAG 문서 생성 및 메타 바인딩
- ☐ W1-3. 벡터DB 구축 (Chroma 암호화)

② 질의응답 엔진 & 가드레일

- ☐ W2-1. RAG 체인 기본 구현 및 출처 바인딩
- ☐ W2-2. Pandas Agent (샌드박스 격리)
- ☐ W2-3. 질문 라우터 & Injection 방지
- ☐ W2-4. 프롬프트 튜닝 & 환각 차단

③ UI & 사용자 보안

- ☐ W3-1. Streamlit UI 및 세션 관리
- ☐ W3-2. 출처 표시 및 입력 유효성 검증
- ☐ W3-3. UI 개선 및 인증/인가 처리

④ 검증, 보안 점검 & 배포

- ☐ W4-1. 테스트 질문 30개 및 보안 시나리오
- ☐ W4-2. 안전한 CI/CD 배포 및 문서화

10. 리스크 관리 및 보안 대응 방안

리스크 항목	세부 영향	대응 및 보완 대책
환각 (Hallucination)	잘못된 수치 제공으로 서비스 신뢰도 하락	수치 연산은 Pandas 샌드박스로 강제 라우팅, Strict Fallback 적용
Prompt Injection	시스템 권한 탈취 및 데이터 무단 유출	Input Sanitization, Pandas AST 코드 실행 제한, 최소 권한 원칙
지역명 중복 (동구 등)	동명이지역 수치 혼동 반환 리스크	'시도 + 시군구' 표준 행정코드 매핑 테이블 구성 및 컨텍스트 강화
API 비용 / Key 유출	예산 초과 및 API 무단 도용 리스크	Key Vault 연동, Rate Limit 설정, GPT-4o-mini 토큰 모니터링

11. 결론 및 승인 요청 사항

요약 및 의결 요청 사항

본 프로젝트는 수치 정확도(Pandas)와 자연어 유연성(RAG)을 결합한 하이브리드 구조에 다층 보안 체계를 더해 안전하고 정확한 시세 조회 서비스를 구현합니다.

1. **의사결정 승인:** 8장에 명시된 의사결정 3건(LLM, 배포환경, 시각화) 권장안 승인 요청
2. **리소스 확정:** 보안 검증 및 개발 수행을 위한 전문 리소스 배정 확정
3. **정책 승인:** 데이터 주기적 갱신 및 보안 감사 정책 승인 요청